



مینی پروژه شماره دو

۱ پرسش یک: سخت‌حاشیه، حاشیه هندسی، دوگان و بردارهای پشتیبان

آ. فرم اولیه SVM سخت‌حاشیه^۱ را بنویسید.

ب. نشان دهید عرض حاشیه برابر $\frac{2}{\|w\|}$ است.

ج. دوگان را استخراج کنید و توضیح دهید چرا تنها نمونه‌های با $\alpha_i > 0$ (بردارهای پشتیبان) در تابع تصمیم^۲ ظاهر می‌شوند.

۲ پرسش دو: حاشیه نرم با نرم ℓ_1 و هینج‌لاس

آ. فرم اولیه نرم‌حاشیه^۳ را با متغیرهای شل‌شدگی^۴ ξ_i بنویسید.

ب. ثابت کنید این فرم معادل کمینه‌سازی $\frac{1}{2}\|w\|^2 + C \sum_i \max(0, 1 - y_i f(x_i))$ است.

ج. با استدلال روشن توضیح دهید پارامتر C چگونه بر تعمیم‌پذیری و تعداد بردارهای پشتیبان اثر می‌گذارد.

۳ پرسش سه: نرم ℓ_2 (شل‌شدگی مربعی) و تفاوت دوگان با ℓ_1

آ. فرم اولیه ℓ_2 -soft margin^۵ را بنویسید.

ب. دوگان متناظر را به‌دست آورید.

ج. تفاوت کران‌های α_i با حالت ℓ_1 و اثر آن بر تعداد و وزن SVها را توضیح دهید.

آ. تعریف «کران معتبر»^۶ را بنویسید و ارتباط آن با وجود نگاشت ویژگی^۷ را توضیح دهید.

ب. با استفاده از خواص بستار^۸، نشان دهید کرنل‌های RBF و چندجمله‌ای معتبرند.

ج. حالات KKT را به‌صورت مرتب بنویسید و نقش هر حالت را توضیح دهید.

¹Hard-Margin SVM

²Decision Function

³Soft-Margin

⁴Slack Variables

⁵ ℓ_2 -Soft Margin (Quadratic Slack)

⁶Valid/PSD Kernel

⁷Feature Map

⁸Closure Properties

۴ پرسش پنج: محاسبه دستی SVM سخت‌حاشیه در \mathbb{R}^2 با نمونه‌های بیشتر

در \mathbb{R}^2 کلاس‌ها به صورت زیر داده شده‌اند. کلاس مثبت:

$$(2, 0), (3, 0), (2, 1), (2, -1)$$

و کلاس منفی:

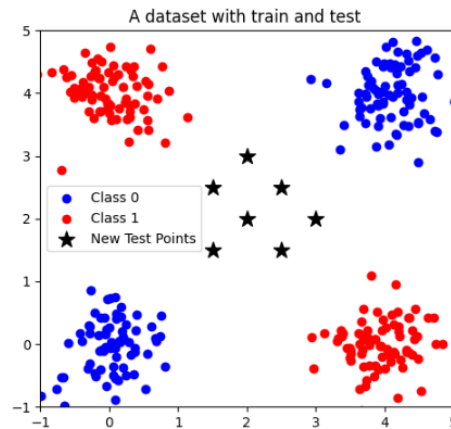
$$(-2, 0), (-3, 0), (-2, -1), (-2, 1).$$

آ. بر مبنای هندسه داده‌ها، ابرصفحه حداکثر حاشیه را حدس بزنید و معادله مرز تصمیم را بنویسید.

ب. ضرایب $w \in \mathbb{R}^2$ و $b \in \mathbb{R}$ را به صورت دستی محاسبه کنید.

ج. بردارهای پشتیبان را مشخص کنید و مقدار حاشیه هندسی و نیز فاصله دو ابرصفحه $w^T x + b = \pm 1$ را دقیق محاسبه نمایید.

۵ پرسش شش: طبقه بندی دسته بندی غیرخطی



دیتاست دو کلاسه‌ی شکل ۵ را در نظر بگیرید که در آن داده‌های آموزشی اولیه متعلق به دو کلاس متمایز بوده و چندین نقطه‌ی جدید (به صورت ستاره‌های سیاه) در ناحیه‌ی مرکزی به آن افزوده شده‌اند. هدف، طراحی و پیشنهاد یک مدل مناسب برای طبقه‌بندی صحیح این داده‌ها است.

آ) اگر بخواهیم با استفاده از شبکه‌های عصبی این مجموعه داده را مدل کنیم، کدام نوع شبکه عصبی را پیشنهاد می‌دهید؟ (برای مثال: Sigmoid, RBF, MLP، و غیره)

ب) به صورت تحلیلی توضیح دهید که ضعف سایر مدل‌های شبکه‌های عصبی آموزش داده شده تا کنون (مانند MLP یا شبکه‌های با توابع فعال‌سازی سراسری) در ایجاد مرز تصمیم در این شکل چیست؟ چرا برخی مدل‌ها در تفکیک خوشه‌های محلی این داده‌ها عملکرد ضعیف‌تری دارند؟

۶ سوال پیاده سازی RBF

هدف این سوال، مدل‌سازی یک سیستم دینامیکی ساده با استفاده از یک شبکه عصبی با تابع شعاعی پایه^۹ است. شما با پیاده‌سازی یک RBFNN استاندارد با ساختاری ایستا^{۱۰} شروع خواهید کرد (بخش اول) و سپس یک شبکه پیشرفته‌تر و تطبیقی^{۱۱} را توسعه خواهید داد که ساختار خود را بر اساس شبکه M-RAN که در مقاله ارائه شده بحث شده است، بهینه‌سازی می‌کند.

Network Neural RBF^۹
Static^{۱۰}
adaptive^{۱۱}

قسمت اول:

۱.۱ بخش اول: شناسایی سیستم با شبکه‌های عصبی RBF

برای این سوال ابتدا یک سیستم ساده شده از نوع ball and beam را مدل‌سازی خواهیم کرد. موقعیت توپ در زمان t ، که با $y(t)$ نشان داده می‌شود، تابعی از دو موقعیت قبلی خود یعنی $y(t-1)$ و $y(t-2)$ و ورودی قبلی به سیستم یعنی $u(t-1)$ است. این رابطه توسط معادله تفاضلی^{۱۲} زیر تعریف می‌شود:

$$y(t) = \frac{y(t-1)}{1 + y(t-2)} + u(t-1)^3$$

در ادامه شما باید یک شبکه RBFNN ایستا بسازید که به عنوان “شناساگر”^{۱۳} عمل می‌کند و خروجی سیستم $(y(t))$ را بر اساس بردار ورودی $(x(t) = [y(t-1), y(t-2), u(t-1)]^T)$ پیش‌بینی می‌کند.

RBFNN ایستا در این بخش، شما یک RBFNN خواهید ساخت که در آن تعداد و ویژگی‌های neuron مخفی قبل از آموزش تعیین می‌شوند. سپس از روش “حد اقل مربعات خطی”^{۱۴} برای آموزش وزن‌های خروجی استفاده خواهید کرد.

ایجاد دیتاست ball and beam

۱.۱.۱

سیگنال $u(t)$ یک موج سینوسی ساده خواهد بود تا دینامیک سیستم را تحریک کند. کدی برای تولید ۱۰۰۰ sample (جفت‌های ورودی خروجی Y/X) به عنوان داده‌های دیتاست بنویسید. برای این کار از سیگنال $u(t) = \sin(2\pi t/250)$ استفاده کنید. $y(0) = y(1) = 0$ را به عنوان مقادیر اولیه در نظر بگیرید. از $t = 2$ تا $t = 999$ تکرار کنید تا دنباله $y(t)$ تولید شود. مجموعه داده نهایی شما شامل بردارهای ورودی $x(t) = [y(t-1), y(t-2), u(t-1)]^T$ و target متناظر آن‌ها یعنی $y(t)$ خواهد بود.

۲.۱.۱

داده‌ها را به دو قسمت برای آموزش و تست تقسیم کنید. برای این کار از ۷۰۰ نقطه اول برای آموزش و ۳۰۰ نقطه باقی‌مانده برای آزمایش (تست) استفاده کنید.

۳.۱.۱

توضیح دهید چرا این مسئله یک “مسئله ی تقریب تابع”^{۱۵} است. تابع مجهولی که RBFNN در تلاش برای یادگیری آن خواهد بود، چیست؟

۲.۱ بخش دوم: پیاده سازی RBFNN ایستا

یک RBFNN معمولاً دارای یک لایه ورودی، یک لایه مخفی با نورون‌های RBF، و یک لایه خروجی خطی است. خروجی شبکه به صورت زیر محاسبه می‌شود (برای سادگی α_0 را صفر در نظر گرفته‌ایم):

$$f(x) = \sum_{k=1}^K \alpha_k \phi_k(x)$$

^{۱۲}equation difference

^{۱۳}identifier

^{۱۴}Squares Least Linear

^{۱۵}problem approximation function

که در آن K تعداد نورون‌های مخفی، α_k وزن‌های خروجی و $\phi_k(x)$ تابع فعال‌سازی RBF گوسی^{۱۶} (بر اساس مقاله) برای نورون k ام است. همچنین $\phi_k(x)$ به صورت زیر تعریف میشود: (علامت $\| \cdot \|$ نشان‌دهنده‌ی نرم اقلیدسی است)

$$\phi_k(x) = \exp\left(-\frac{1}{\sigma_k^2}\|x - \mu_k\|^2\right)$$

۱.۲.۱

نقش مرکز نورون (μ_k) و عرض (σ_k) آن را توضیح دهید. کم و زیاد شدن هر پارامتر چگونه بر پاسخ نورون به یک ورودی تأثیر می‌گذارد؟

۲.۲.۱

تابعی برای یک نورون تعریف کنید که فعال‌ساز RBF گوسی را با گرفتن بردار ورودی x ، مرکز μ_k و عرض σ_k محاسبه کند. (این تابع را با ورودی و مرکز یکسان $[1, 1]$ و عرض ۱ تست کنید) خروجی فعال‌ساز چه مقدار را نشان میدهد؟ توضیح دهید که این خروجی به چه معناست؟

۳.۱ بخش سوم: آموزش از طریق حداقل مربعات خطی (LLS)

با ثابت بودن مراکز و عرض‌ها، خروجی RBFNN یک ترکیب خطی از فعال‌سازهای RBF است. این بدان معناست که شما می‌توانید برای محاسبه وزن‌های خروجی بهینه ($\alpha = [\alpha_1, \dots, \alpha_k]^T$) از LLS استفاده کنید. بواقع شما باید دستگاه معادلات خطی $\Phi\alpha = Y$ را حل کنید، که در آن Y بردار target و Φ ماتریس ای به صورت $\Phi_{ij} = \phi_j(x_i)$ است.

۱.۳.۱

با نوشتن کدی، ماتریس Φ را برای داده‌های آموزش خود بسازید. شبکه rbf ایستا را بوسیله LLS آموزش (روی مجموعه آموزش) دهید. تعداد مراکز انتخاب شده و مقدار عرض انتخاب شده را گزارش کنید. بردار وزن‌های بهینه خروجی α ، و خروجی‌ها را برای مجموعه‌ی آموزش بدست آورید. مدل را روی مجموعه تست آزمایش کنید و خروجی‌های پیش‌بینی شده را بدست آورید.

توجه کنید که:

- K مرکز (μ_k) را با انتخاب تصادفی K داده از مجموعه آموزشی خود انتخاب کنید.
- تمام عرض‌های (σ_k) را روی یک مقدار ثابت تنظیم کنید. یک نقطه شروع خوب میتواند میانگین فاصله بین مراکز انتخاب شده باشد.

همچنین تابعی برای ارزیابی شبکه آموزش‌دیده خود بنویسید. از ریشه میانگین مربعات خطا^{۱۷} به عنوان معیار ارزیابی عملکرد شبکه خود استفاده کنید. مقدار RMSE را برای هر دو مجموعه تست و آموزش گزارش دهید.

۲.۳.۱

خروجی‌های پیش‌بینی شده در مجموعه آموزش را با خروجی‌های واقعی در یک نمودار بر اساس اندیس نمونه‌ها نمایش دهید (محور x اندیس نمونه‌ها و محور y مقادیر خروجی).

۳.۳.۱

نمودار مشابه قسمت قبلی برای مجموعه تست ایجاد کنید. این نمودار را تحلیل کنید. بیشترین خطا در کدام قسمت رخ داده است؟ چرا؟ تحلیل کنید.

Gaussian^{۱۶}
Error Squared Mean Root^{۱۷}

۴.۳.۱

توضیح دهید چرا این فرآیند آموزش بوسیله ی LLS بسیار سریع تر از “backpropagation” مبتنی بر گرادینت کاهشی” است که در پرسپترون های چندلایه^{۱۸} استفاده می شود.

۵.۳.۱

همچنان σ را ثابت در نظر بگیرید این بار شبکه هایی برای مقادیر مختلف $K = 10, 20, 50, 100, 200$ آموزش دهید. مدل ها را روی داده های تست ارزیابی کنید سپس RMSE تست را به صورت تابعی از K رسم کنید. بهترین مقدار k را گزارش کنید.

۶.۳.۱

توصیف کنید که اگر K خیلی کوچک یا خیلی بزرگ باشد چه اتفاقی می افتد. این موضوع را به “کم برازش”^{۱۹} و “بیش برازش”^{۲۰} ربط دهید.

۷.۳.۱

K را بر روی بهترین مقداری که پیدا کردید ثابت کنید و اکنون شبکه را با مقادیر مختلف σ آموزش داده و روی داده های تست ارزیابی کنید ($\sigma = 0.5, 1, 5, 7, 10$).

همچنین RMSE تست را به صورت تابعی از σ رسم کنید. بهترین مقدار σ را گزارش کنید. همچنین خروجی های بدست آمده از شبکه با بهترین σ (و بهترین k) روی مجموعه تست ارزیابی کرده و مقادیر پیش بینی شده را با مقادیر خروجی واقعی مقایسه کنید و در نموداری مانند نمودار ۳.۳.۱ نشان دهید.

۸.۳.۱

توصیف کنید که وقتی σ خیلی کوچک یا خیلی بزرگ است چه اتفاقی می افتد؟ این موضوع چگونه بر توانایی “تعمیم پذیری”^{۲۱} شبکه تأثیر می گذارد؟

۹.۳.۱

در انتخاب “بهترین” ساختار شبکه (شبکه با بهترین k و σ) با چه چالش هایی روبرو شدید؟ توضیح دهید.

۴.۱ بخش چهارم: تلاش برای حل چالش ها

۱.۴.۱

در قسمتهای قبلی شما از روش استاندارد کمترین مربعات خطی (LLS) برای یافتن وزن های بهینه استفاده کرده اید. زمانی که K بسیار بزرگ باشد میتواند سبب مشکل در تعمیم پذیری شود. یکی از روش های حل این موضوع آموزش با LLS همراه با Regularization L2 است. تابعی برای آموزش مدل RBFNN Static با استفاده از Regularization L2 با انتخاب مرکز K (μ_k) برای یک مقدار بزرگ K و عرض های σ ثابت تعریف کنید و بردار وزن های بهینه و خروجی ها را بدست آورید. مدل آموزش دیده را روی مجموعه تست ارزیابی کنید و خروجی های پیش بینی شده را با خروجی های واقعی مقایسه کنید (میتوانید ضریب رگولاریزیشن را یکی از اعداد 0.001, 0.01, 0.1, 1, 10 قرار دهید). تفاوت خروجی حاصل با و بدون Regularization برای مقدار σ و k انتخابی مقایسه کنید.

MLPs^{۱۸}
underfitting^{۱۹}
overfitting^{۲۰}
generalize^{۲۱}

۲.۴.۱

بردار وزن‌های بهینه α زمانی که از تابع Regularization L2 استفاده می‌کنیم از رابطه ی زیر بدست می‌آید که در آن λ ضریب رگولاریزیشن است:

$$(\Phi^T \Phi + \lambda I) \alpha = \Phi^T Y$$

نقش پارامتر λ را توضیح دهید؟ با افزایش یا کاهش زیاد این پارامتر چه اتفاقی می‌افتد؟

۵.۱ بخش پنجم

۱.۵.۱

بار دیگر مقدار σ را ثابت در نظر بگیرید و قسمت ۱.۳.۱ را با یافتن k مرکز (μ_k) با استفاده از clustering K-Means^{۲۲} بجای انتخاب رندوم حل کنید و وزن های بهینه را بدست آورید. مقدار RMSE تست را گزارش دهید.

همچنین مجدداً خروجی های پیش بینی شده توسط مدل روی داده های تست و خروجی های واقعی را در نموداری نمایش داده و مقایسه کنید (توجه کنید که k حتماً بزرگتر از ۱۰ انتخاب شود) نتایج را با زمانی که از K مرکز رندوم استفاده می‌کردید مقایسه کنید.

۲.۵.۱

حال با استفاده از مقادیر مراکز بدست آمده از سوال قبل و استفاده از استراتژی Nearest-Neighbor^{۲۳} تابعی بنویسید که عرض σ برای هر مرکز محاسبه کند. برای به کار بردن این روش عرض σ هر نورون را بر اساس میانگین فاصله تا p نزدیکترین مراکز بدست آورد یعنی برای بدست آوردن عرض σ هر نورون، فاصله اقلیدسی مرکز آن نورون تا تمام مراکز (بجز خودش) را بدست آورید. فواصل به دست آمده را به صورت صعودی مرتب کنید و میانگین فاصله تا p تا از نزدیکترین مراکز را بدست آورید (میانگین p فاصله ی کوچکتر)؛ این مقدار عرض آن نورون می باشد. با استفاده از این مراکز بار دگر وزن های بهینه را بدست آورده و گزارش کنید ($p = 2$ قرار دهید).

مقادیر RMSE روی داده‌های تست و آموزش را گزارش کنید. خروجی های پیش بینی شده روی داده‌های تست و خروجی های واقعی را در نموداری نمایش داده و مقایسه کنید. نتایج این قسمت را با نتایج قسمت قبل (زمانی که از σ ثابت استفاده کردید) مقایسه کنید.

۳.۵.۱

توضیح دهید چرا clustering K-Means از نظر تئوری در مقایسه با انتخاب تصادفی، روش بهتری برای انتخاب مراکز RBF است؟

قسمت دوم: پیاده‌سازی RBFNN تطبیقی با الهام از M-RAN

قسمت اول سوال نقطه ضعف کلیدی های RBFNN ایستا را نشان داد؛ یافتن توپولوژی^{۲۴} مناسب چنین شبکه‌ای دشوار و ناکارآمد است.

در مقاله ارائه شده راه حلی برای این موضوع پیشنهاد شده است؛ شبکه‌ای که بر اساس نیاز می‌تواند نورون‌ها و لایه‌های پنهان را افزایش دهد و یا هرس کند در این بخش نسخه ی ساده شده‌ای از M-RAN پیشنهاد شده در مقاله را پیاده‌سازی می‌کنید.

در این روش برای آموزش مدل به‌جای استفاده همزمان از کل مجموعه آموزشی، اکنون داده‌ها به صورت ترتیبی، یعنی هر بار یک داده برای پردازش به مدل داده‌خواهد شد. شبکه با صفر نورون پنهان شروع می‌شود و فقط در صورت نیاز نورون‌ها اضافه

^{۲۲} clustering K-Means
^{۲۳} Nearest-Neighbor
^{۲۴} topology

می‌شوند. طبق مقاله، یک unit hidden جدید برای یک نمونه (x_n, y_n) اضافه می‌شود، اگر داده جدید^{۲۵} باشد و خطا قابل توجه^{۲۶} باشد.

پس معیارهای رشد شبکه شما عبارتند از:

۱. تازگی^{۲۷}: ورودی x_n از مراکز موجود دور است:

$$\|x_n - \mu_n\| > \varepsilon$$

که μ_n نزدیکترین مرکز به x_n است.

۲. خطا: خطای شبکه بزرگ باشد؛ یعنی:

$$|y_n - f(x_n)| > e_{\min}$$

۱.۲ بخش اول: یادگیری ترتیبی^{۲۸} و معیار رشد

۱.۱.۲

ابتدا تابعی بنویسید که یک نمونه جدید (x_n, y_n) ، مقدار پیش‌بینی شده، و آستانه ε و e_{\min} را دریافت می‌کند. اگر نیاز به اضافه‌کردن نورون وجود داشته‌باشد True و در غیر این صورت False را برمیگرداند. (میتوانید با مقادیر $\varepsilon = 1$ و $e_{\min} = 0.5$ و چند مقدار فرضی برای ورودی و خروجی واقعی و مقدار پیش‌بینی شده تابع را تست کنید)

۲.۱.۲

چرا هر دو معیار برای رشد شبکه ضروری هستند؟ چه اتفاقی می‌افتد اگر فقط از معیار خطا استفاده می‌کردیم؟ چه اتفاقی می‌افتد اگر فقط از معیار تازگی استفاده می‌کردیم؟ افزایش و کاهش ε چه تاثیری در شبکه دارد؟

۲.۲ بخش دوم (امتیازی): پیاده‌سازی RBFNN تطبیقی با استراتژی هرس^{۲۹}

در این قسمت شما باید شبکه RBFNN تطبیقی بر اساس M-RAN گفته‌شده در مقاله را به صورت کامل پیاده‌سازی کنید برای این منظور شما در هر epoch از فرایند آموزش مدل باید تنها یک sample به شبکه بدهید همچنین شما از استراتژی هرس گفته شده در مقاله استفاده می‌کنید که در قسمت زیر توضیح داده شده است.

هرس: برخی از نورون‌هایی که اضافه می‌شوند ممکن است بعداً نقش کمی در تولید خروجی داشته‌باشند و به واقع redundant تلقی شوند. برای حفظ سادگی و عدم پیچیدگی شبکه ایجادشده الگوریتم M-RAN واحدهای پنهان^{۳۰} را که سهم کمی در خروجی شبکه دارند هرس می‌کند. مقاله یک استراتژی قوی برای هرس کردن پیشنهاد می‌کند (بخش ۲.۲). این استراتژی هرس، با حذف نورون‌هایی که در یک دوره زمانی تاثیر کمی روی خروجی دارند سبب فشردگی مدل می‌شود.

استراتژی هرس:

- محاسبه مشارکت: برای هر نورون k در نمونه n ، مشارکت خروجی آن را پیدا کنید:

$$o_k^n = \alpha_k \times \phi_k(x_n)$$

novel^{۲۵}
significant^{۲۶}
Novelty^{۲۷}
Sequential^{۲۸}
Pruning^{۲۹}
hidden^{۳۰}

- نرمال‌سازی مشارکت: حداکثر خروجی مطلق را بیابید: $o_{\max}^n = \max_k(|o_k^n|)$ و خروجی نرمال‌شده را برای هر نورون محاسبه کنید:

$$r_k^n = \frac{|o_k^n|}{o_{\max}^n}$$

- بررسی اهمیت: یک نورون در نمونه n بی‌اهمیت^{۳۱} است اگر: $r_k^n < \delta$
 - تصمیم هرس: نورون k را حذف کنید اگر برای M مشاهده متوالی «بی‌اهمیت» بوده باشد.
- برای پیاده‌سازی هرس در کد خود، باید یک شمارنده پایدار^{۳۲} برای هر نورون استفاده کنید (مثلاً، در آرایه‌ای به نام `pruning_counters`):

برای پیاده‌سازی در کد خود مراحل زیر را برای نمونه فعلی x_n انجام دهد:

۱. مشارکت خروجی o_k^n را برای همه K نورون محاسبه کنید.
۲. خروجی‌های نرمال‌شده r_k^n را برای همه K نورون محاسبه کنید.
۳. در یک حلقه، هر نورون k را بررسی کنید:
 - اگر $r_k^n < \delta$ (بی‌اهمیت است) `pruning_counters[k]` را افزایش دهید^{۳۳}
 - اگر $r_k^n > \delta$ (با اهمیت است) `pruning_counters[k]` را برابر ۰ قرار دهید^{۳۴}
۴. تمام اندیس‌های k را که در آن‌ها `pruning_counters[k] > M` است، پیدا کنید و نورون‌ها و آرایه‌های شمارنده‌ی مربوط به آن‌ها را حذف کنید.
۵. وضعیت شبکه را به‌روزرسانی کنید.

۱.۲.۲

اکنون، منطق رشد (از بخش اول) و منطق هرس پیشرفته (از بخش ۱.۲) را در یک حلقه آموزش واحد ادغام و به صورت کامل پیاده‌سازی کنید و مدل را آموزش دهید.

فرایند آموزش برای هر نمونه (x_n, y_n) در هر `epoch` باید به صورت زیر انجام شود:

- خروجی شبکه $f(x_n)$ (یا همان \hat{y}) و خطا $(e_n = y_n - f(x_n))$ را محاسبه کنید.
- معیارهای رشد را بررسی کنید.
- در صورت تایید و نیاز نورون جدید را به شبکه اضافه کنید.
- اگر نورون جدید اضافه شد:
 - مرکز آن را x_n قرار دهید $\mu_{k+1} = x_n$
 - وزن آن را e_n تنظیم کنید $\alpha_{k+1} = e_n$
 - عرض آن را با رابطه: $\sigma_{k+1} = \kappa \|x_n - \mu_n\|$ تنظیم کنید (κ ضریب همپوشانی است و می‌توانید آن را در ابتدا ۸.۰ انتخاب کنید)
 - یک عدد ۰ به آرایه `pruning_counters` اضافه کنید (برای نورون جدید).
- اگر نورون جدیدی به شبکه اضافه نشد:

- تمام وزن‌های خروجی موجود α_k را با استفاده از قانون “حداقل میانگین مربعات”^{۳۵} به‌روزرسانی کنید (این قانون به صورت: $\alpha_k(n) = \alpha_k(n-1) + \eta \cdot e_n \cdot \phi_k(x_n)$ می‌باشد که در آن η نرخ یادگیری^{۳۶} است.)

^{۳۱}insignificant
^{۳۲}persistent
^{۳۳}increment
^{۳۴}reset
^{۳۵}LMS
^{۳۶}rate learning

- پس از رشد یا بهروزرسانی هرس را انجام دهید.

نکات مهم زیر را برای انجام این قسمت در نظر داشته باشید:

توجه کنید که برای انجام آموزش شما باید مقادیر مناسبی را برای هایپرپارامترها^{۳۷} انتخاب کنید $(\kappa, M, \eta, \delta, e_{\min}, \varepsilon)$. می‌توانید برای این کار از روش هایی مثل search grid استفاده کنید. با قرار دادن $\delta = 0.1, \kappa = 0.8, M = 60$ و $\eta = 0.05$ با استفاده از روش search grid مقادیر مناسبی برای e_{\min} و ε روی بازه‌ی دلخواه انتخابی برای ε و $e_{\min} \in \{0.05, 0.1, 0.15, 0.2\}$ بدست آورید. (همچنین می‌توانید شبکه را به صورت تطبیقی نیز پیاده‌سازی کنید یعنی همزمان که وزن‌ها را آموزش می‌دهید، هایپرپارامترها را نیز آموزش داده و بهترین هایپرپارامترها را بدست آورید) در پیاده‌سازی شبکه خود کد خود را مجهز کنید تا ذخیره‌ای از تعداد نورون‌های پنهان در هر مرحله از فرآیند آموزش را نگه‌دارد.

۲.۲.۲

در نهایت RBFNN تطبیقی خود را بر روی مجموعه آموزشی، آموزش دهید. سپس، عملکرد نهایی آن را بر روی مجموعه آزمایش ارزیابی کنید. نتایج و RMSE آن را گزارش دهید. خروجی‌های پیش‌بینی شده را با خروجی واقعی در یک نمودار نمایش داده و تحلیل کنید. همچنین بهترین هایپرپارامترهای پیدا شده را گزارش کنید.

۳.۲.۲

نموداری ایجاد کنید که نشان دهد چگونه تعداد نورون‌های پنهان در شبکه تطبیقی شما در طول دوره آموزش تغییر کرده است. (مانند شکل A۲ یا A۳ در مقاله)

۴.۲.۲

تعداد نهایی نورون‌ها و RMSE نهایی روی داده‌های تست را برای بهترین RBFNN ایستا و RBFNN تطبیقی خود مقایسه کنید.

۵.۲.۲

بر اساس نتایج خود، در مورد مزایا و معایب رویکرد تطبیقی M-RAN در مقایسه با RBFNN ایستا بحث کنید. آیا شبکه تطبیقی موفق شد توپولوژی شبکه حداقلی^{۳۸} و در عین حال با دقت بالا را پیدا کند؟ چرا این امر برای کاربردهای دنیای واقعی^{۳۹} مهم است؟

۷ کدنویسی - SVM خطی و مطالعه پارامتر C

داده‌ها: Breast Cancer Wisconsin (Diagnostic).

اصل تکرارپذیری: در همه تقسیم‌بندی‌ها و سازنده‌ها، random_state را برابر دو رقم آخر شماره دانشجویی تنظیم کنید.

آ. آماده‌سازی. داده را بارگذاری کنید؛ به صورت لایه‌مند به train، validation و test (پیشنهادی ۶۰/۲۰/۲۰) تقسیم کنید. تنها روی ویژگی‌ها استانداردسازی انجام دهید. یک PCA دو بُعدی صرفاً برای نمایش آماده کنید (مدل‌ها در فضای اصلی آموزش ببینند).

ب. آموزش و گزارش حاشیه. یک SVC(kernel='linear') آموزش دهید. با رابطه $w = \sum_i \alpha_i y_i x_i$ (پس از استانداردسازی)، مقدار $1/\|w\|$ را محاسبه و گزارش کنید. روی validation و test شاخص‌های Accuracy، F1، Recall، Precision و ROC-AUC را اندازه‌گیری و گزارش کنید.

hyperparameters^{۳۷}

minimal^{۳۸}

applications real-world^{۳۹}

ج. مطالعه C . برای $C \in \{0.01, 0.1, 1, 10, 100\}$ مدل را بازآموزی کنید. برای هر C ، شاخص‌های فوق و تعداد **support vectors** را استخراج کرده و در یک جدول منظم ارائه دهید. تغییرات بایاس/واریانس را تحلیل مکتوب کنید.

د. نمودارهای ارزیابی. برای بهترین C (انتخاب بر مبنای validation و تأیید روی test)، منحنی‌های ROC و Precision-Recall را رسم و تفسیر کنید.

در انجام این تمرین حتماً به نکات زیر توجه کنید:

- موعد تحویل این تمرین، ساعت ۱۸:۰۰ روز ۳۰ آبان ماه ۱۴۰۴ است.
- برای گزارش لازم است که پاسخ هر سؤال و زیربخش هایش به ترتیب و به صورت مشخص نوشته شده باشند. بخش زیادی از نمره به توضیحات دقیق و تحلیل های کافی شما روی نتایج بستگی خواهد داشت.
- لازم است که در صفحه اول گزارش خود لینک مخزن گیت هاب و گوگل کولب مربوط به مینی پروژه خود را درج کنید. درخصوص گیت هاب، یک مخزن خصوصی درست کنید و آی دی های MJAHMADEE، erfany2AJ و AliBagheriNejad، ParisaGhorbani را به عنوان Collaborator به مخزن اضافه کنید. پروژه های گیت هاب می بایست در انتهای ترم پابلیک شوند. در مقابل، لینک گوگل کولب را در حالتی که دسترسی عمومی دارد به اشتراک بگذارید. دفترچه گوگل کولب باید به صورت منظم و با بخش بندی مشخص تنظیم شده باشد و خروجی سلول های اجرا شده قابل مشاهده باشد. در گیت هاب نیز یک مخزن برای درس و یک پوشه مجزا برای هر مینی پروژه ایجاد کنید.
- (آموزش پرایوت کردن مخزن گیت هاب و آموزش افزودن Collaborator به مخزن گیت هاب)
- چرا از دفترچه گوگل کولب؟ شما نباید به فراخوانی فایل های خارج از محیط نیاز داشته باشید؛ مطابق آموزش های ارائه شده ملزم هستید از دستور [gdown](#) استفاده کنید و مسیرهای فایل ها را طوری تنظیم کنید که صرفاً با اجرای سلول ها، امکان فراخوانی و خواندن فایل ها توسط هر کاربری وجود داشته باشد.
- در تمامی مراحل تعریف داده و مدل و هر جای دیگری که مطابق آموزش های ویدیویی و به لحاظ منطقی نیاز است، Random State را برابر با دو رقم آخر شماره دانشجویی خود در نظر بگیرید.
- استفاده از ابزارهای هوشمند (مانند ChatGPT) در کمک گرفتن برای بهبود کدها مجاز است؛ اما لازم است تمام جزئیات مواردی که در خروجی های مختلف گزارش خود عنوان می کنید را به خوبی خوانده، درک و تحلیل کرده باشید. استفاده از این ابزارهای هوشمند در نوشتن گزارش و تحلیل ها ممنوع است.
- در جاهایی که با توجه به دو رقم آخر شماره دانشجویی خود محدود به انتخاب عددی معین یا داده ای خاص شده اید، برای تست های اضافه تر و نمایش بهبود در نتایج خود، مجاز هستید از مقادیر دیگر هم استفاده کنید.
- رعایت نکات بالا به حرفه ای تر شدن شما کمک خواهد کرد و اهمیتی معادل مطالب درسی فراگرفته شده دارد؛ بنابراین، در صورت عدم رعایت یک یا چند مورد از این نکات، از نمره تمرین شما کاسته خواهد شد.
- آی دی پرسش هرگونه سؤال درخصوص مینی پروژه شماره ۲